

# Разработка алгоритма классификации бактерий методом спектроскопии комбинационного рассеяния света

**Байкова Т.В.**

преподаватель кафедры физики и технической механики ИПТИП РТУ МИРЭА

**Гончуков С.А.**

д.ф.-м.н., профессор кафедры лазерной физики НИЯУ МИФИ

***Аннотация.** В работе представлен подход к автоматической классификации бактерий на основе их рамановских спектров с учётом плазмонного усиления (ГКР). В качестве объектов исследования использованы золотистый стафилококк (*Staphylococcus aureus*) и клебсиелла пневмония (*Klebsiella pneumoniae*) на наноструктурированных подложках: золотые сферические наночастицы и углеродные наностенки с Au-плёнкой. Предложен алгоритм обработки спектров, включающий динамически настраиваемое сглаживание фильтром Савицкого-Голея, MinMax-масштабирование, извлечение пиковых и статистических признаков, а также классификацию методом случайного леса. Показано, что сочетание поверхностно-усиленной спектроскопии и алгоритмов ИИ обеспечивает высокую точность ( $\geq 90\%$ ) распознавания грам-положительных и грам-отрицательных бактерий.*

***Ключевые слова:** рамановская спектроскопия, SERS/ГКР, алгоритм классификации, Savitzky–Golay, RandomForest.*

## **Введение**

Быстрая и точная диагностика бактериальных инфекций на ранней стадии критически важна для своевременного начала терапии и предупреждения осложнений. Традиционные методы (культуральное выращивание, микроскопия, окрашивание по Граму) требуют часов или дней и могут давать ложные результаты при низких концентрациях микроорганизмов. Спектроскопия комбинационного рассеяния света позволяет получать «молекулярный отпечаток» образца без использования красителей, однако природная интенсивность рамановского сигнала низка. Применение наноструктурированных подложек с эффектом поверхностно-усиленного рамановского рассеяния (SERS или ГКР) повышает чувствительность [1,2,3]. Цель этой работы - разработать алгоритм автоматической классификации бактерий по их СКР-спектрам, усиливаемым этим механизмом, и

оценить эффективность подхода на примерах грам-положительных и грам-отрицательных культур.

### Методика эксперимента

Спектры регистрировали на спектрометре Nicolet Almega XR с возбуждением неодимового лазера ( $\lambda = 532$  нм, 20 мВт). Считали компоненты Stokes-сдвига в диапазоне  $400\text{--}3100\text{ см}^{-1}$  при разрешении  $2\text{ см}^{-1}$ . Волновую шкалу калибровали по пику кремния ( $521\text{ см}^{-1}$ ). В целях уменьшения влияния флуоресценции использовали режим фотообесцвечивания в течение 30 секунд перед записью спектров комбинационного рассеяния света.

Для автоматической обработки и классификации спектральных данных, полученных методом спектроскопии комбинационного рассеяния света (СКР) с плазмонным усилением (ГКР), на языке программирования Python был разработан комплексный алгоритм, объединяющий этапы предобработки сигналов, извлечения признаков, снижения размерности и классификации.

На первом этапе реализации алгоритма выполнялось сглаживание спектров с использованием фильтра Савицкого–Голея. Как показано на рис. 1 для устранения вариабельности масштаба интенсивностей между разными спектрами применялось нормирование с помощью масштабирования признаков в диапазоне  $[0,1]$  (MinMaxScaler).




Рис. 1. Спектры КР бактерии *Staphylococcus aureus* (Синий цвет) и *Klebsiella pneumoniae* (оранжевый цвет).

После предобработки для каждого спектра вычислялся вектор признаков, представляющие собой спектральные «отпечатки» бактерий, включающий: положение основного пика (максимального значения интенсивности по оси частот); интенсивность основного пика; статистические характеристики (среднее значение интенсивности, стандартное отклонение и медиану интенсивностей по спектру). Данная процедура позволяла существенно сократить размерность данных при сохранении их диагностически значимой информации.

В качестве основного алгоритма классификации использовался метод случайного леса (Random Forest Classifier), обладающий высокой устойчивостью к переобучению и способностью учитывать сложные нелинейные зависимости между признаками. Для повышения точности модели и оптимизации её параметров применялся метод перебора по сетке (GridSearchCV) с трёхкратной перекрёстной проверкой (cross-validation, cv=3). Оптимизируемыми гиперпараметрами являлись: количество деревьев (n\_estimators), максимальная глубина деревьев (max\_depth).

Таким образом, весь процесс классификации спектров включал предобработку данных (масштабирование интенсивностей), извлечение признаков (положение и амплитуда максимального пика, статистические моменты), снижение размерности методом главных компонент (PCA) и классификацию с использованием случайного леса (Random Forest Classifier).

Разработанная архитектура алгоритма позволяет легко масштабировать систему под новые спектральные базы данных, а также адаптировать её для распознавания более широкого спектра бактериальных агентов.

### **Результаты и их обсуждение**

В ходе эксперимента было подтверждено значительное усиление сигналов спектров комбинационного рассеяния света (СКР) при использовании наноструктурированных подложек [5-7].

Классификационная модель была обучена и протестирована с использованием 80 % спектров для обучения и 20 % для валидации. Полученные метрики качества модели:

- accuracy (доля правильных классификаций) 92%;
- precision (точность предсказания класса для положительного случая) 0.91 для *Staphylococcus aureus*, 0.93 для *Klebsiella pneumoniae*;
- recall (полнота - доля правильно обнаруженных положительных примеров) 0.92 и 0.90 соответственно.

Результаты применения алгоритма с предварительным сглаживанием спектров фильтром Савицкого-Голея не показали существенного улучшения качества классификации, что указывает на достаточную чистоту исходных спектров и минимальное влияние фонового шума в экспериментальных данных.

Анализ данных показывает, что использование механизма гигантского комбинационного рассеяния (ГКР) в сочетании с алгоритмами машинного обучения позволяет достичь высокой надёжности классификации даже при небольшом объёме данных и невысоком уровне сигналов.

Выигрыш в чувствительности за счёт наноструктурированных подложек делает возможным дальнейшее применение предложенной методики для ранней диагностики бактериальных инфекций в клинической практике, а также для мониторинга качества воды и пищевых продуктов.

### **Заключение**

Предложенный алгоритм классификации бактерий на основе SERS-спектров демонстрирует высокую точность и позволяет детектировать как грам-положительные, так и грам-отрицательные культуры при низких концентрациях благодаря плазмонному усилению. Адаптивные параметры предобработки и компактный набор признаков делают модель универсальной для дальнейшего расширения базы патогенов и интеграции в портативные диагностические устройства.

### **Список использованных источников**

1. *S.A. Gonchukov, T.V. Baikova, M.V. Alushin, T.S. Svistunova, S.A. Minaeva, A.A. Ionin, S.I. Kudryashov, I.N. Saraeva, D.A. Zayarny.* Single bacterium detection using SERS. // Journal of Physics: Conference Series. – 2016. – 691.
2. *Tsvetkov, M. Y., Evlashin, S. A., Mironovich, K. V., Minaeva, S. A., Suetin, N. V., & Bagratashvili, V. N.* Ag on carbon nanowalls mesostructures for SERS// Proceedings of SPIE – The International Society for Optical Engineering. – 2015. – с. 9450. – <https://doi.org/10.1117/12.2073252>
3. *V.O. Yukhymchuk, O.M. Hreshchuk, M.Ya. Valakh, Ye.G. Gule, M.A. Skoryk, V.S. Efanov, N.A. Matveevskaya, T.G. Beynik.* Design and characterization of nanostructured SERS substrates based on gold nanostars. // Semiconductor Physics, Quantum Electronics & Optoelectronics. – 2017. – V. 20. – N 1. – p. 41-47.

4. *Harz M, Kiehntopf M, Stöckel S, Rösch P, Deufel T, Popp J.* Analysis of single blood cells for CSF diagnostics via a combination of fluorescence staining and micro-Raman spectroscopy.// *The Analyst.* – 2008. – 133. – p. 1416-1423. – PMID 18810290 DOI: 10.1039/B716132H
5. *Haynes, C. L., McFarland, A. D. and Van Duyne, R. P.* Surface-Enhanced Raman Spectroscopy// *Analytical Chemistry.* – 2005. – No77. – c. 338A–346A.
6. *Cialla-May D, Krafft C, Rösch P, Deckert-Gaudig T, Frosch T, Jahn IJ, Pahlow S, Stiebing C, Meyer-Zedler T, Bocklitz T, Schie I, Deckert V, Popp J.* Raman Spectroscopy and Imaging in Bioanalytics.// *Analytical Chemistry.* – 2021. – DOI: 10.1021/acs.analchem.1c03235.
7. *Guo S, Rösch P, Popp J, Bocklitz T.* Modified PCA and PLS: Towards a better classification in Raman spectroscopy-based biological applications.// *Journal of Chemometrics.* – 2020. – 34. – DOI: 10.1002/Cem.3202.